یادگیری عمیق

مدرس: محمدرضا محمدی

بهار ۱۴۰۲

یادگیری بازنمایی

Representation Learning

یادگیری بازنمایی مقابله‌ای (Contrastive)

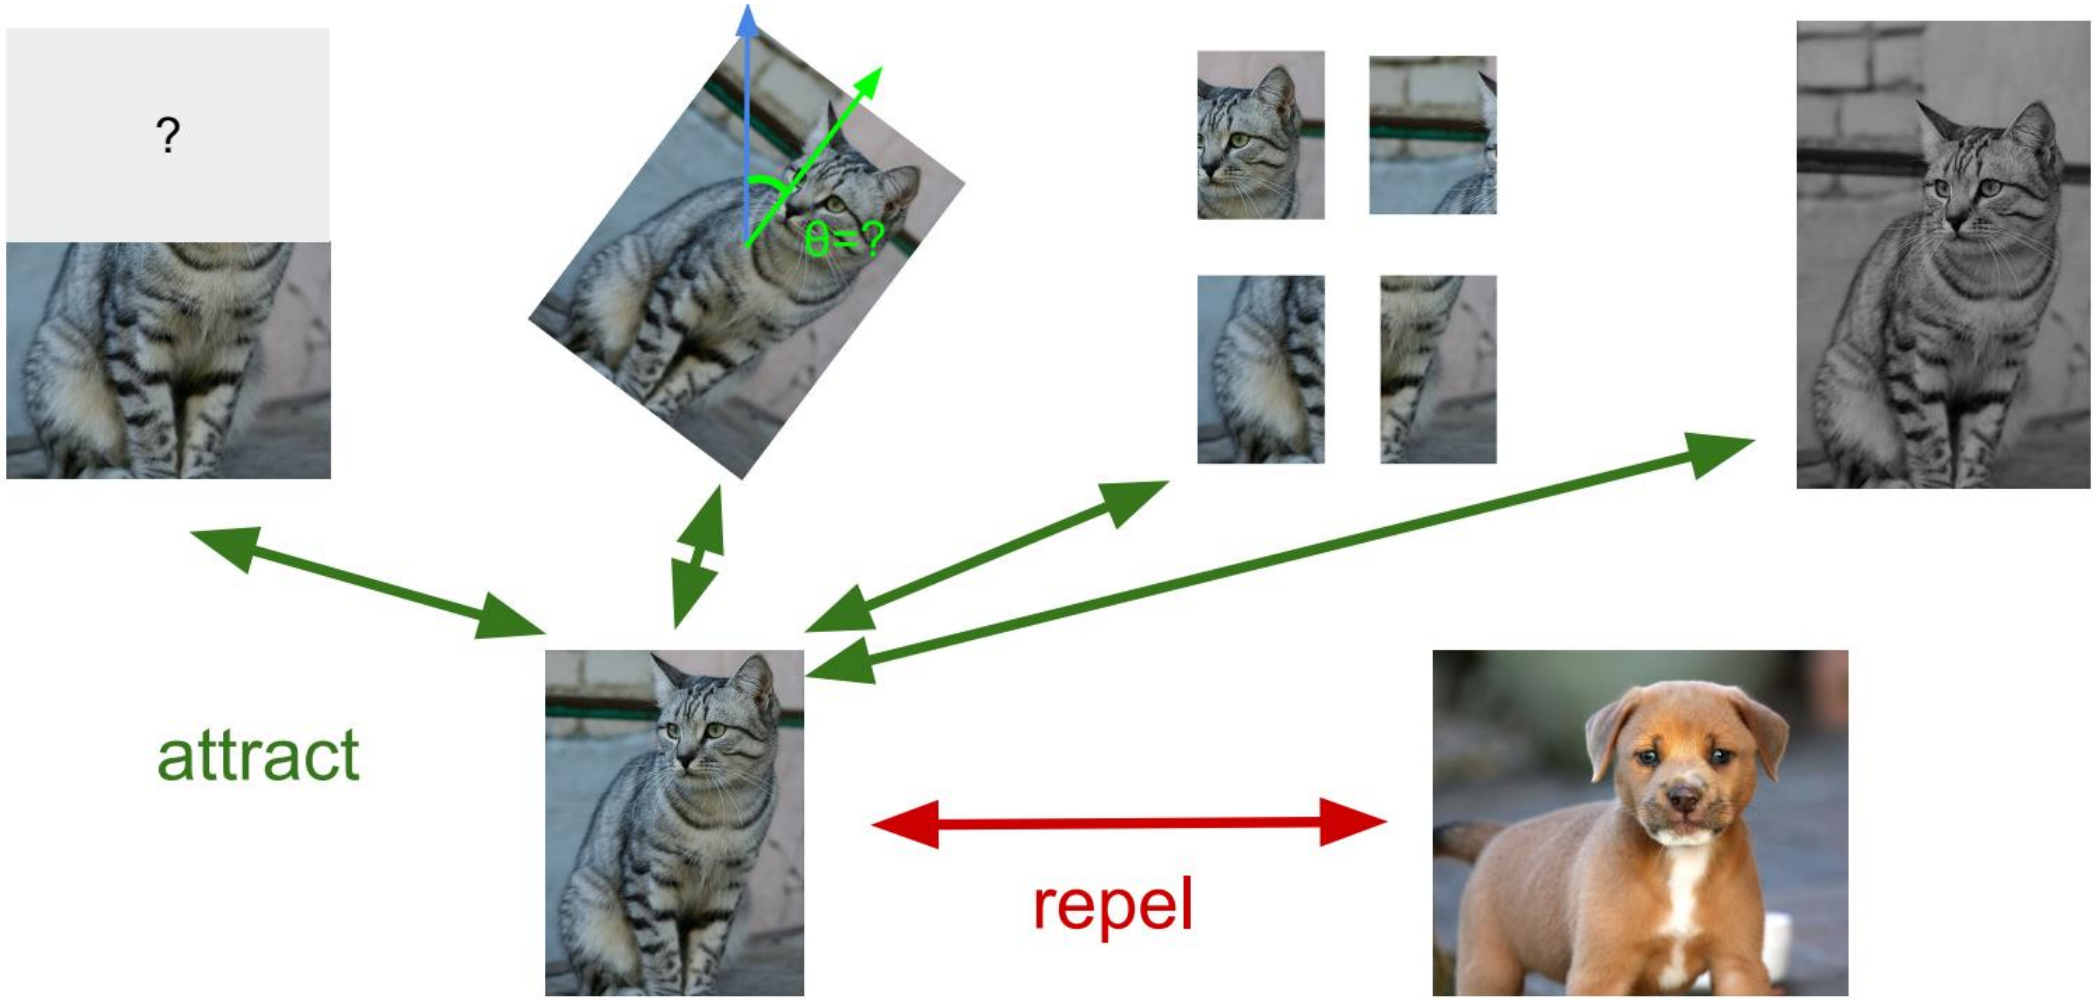

Based on cs231n by Fei-Fei Li, Jiajun Wu, Ruohan Gao http://cs231n.stanford.edu/slides/2022/lecture_14_jiajun.pdf

یادگیری بازنمایی مقابله‌ای (Contrastive)

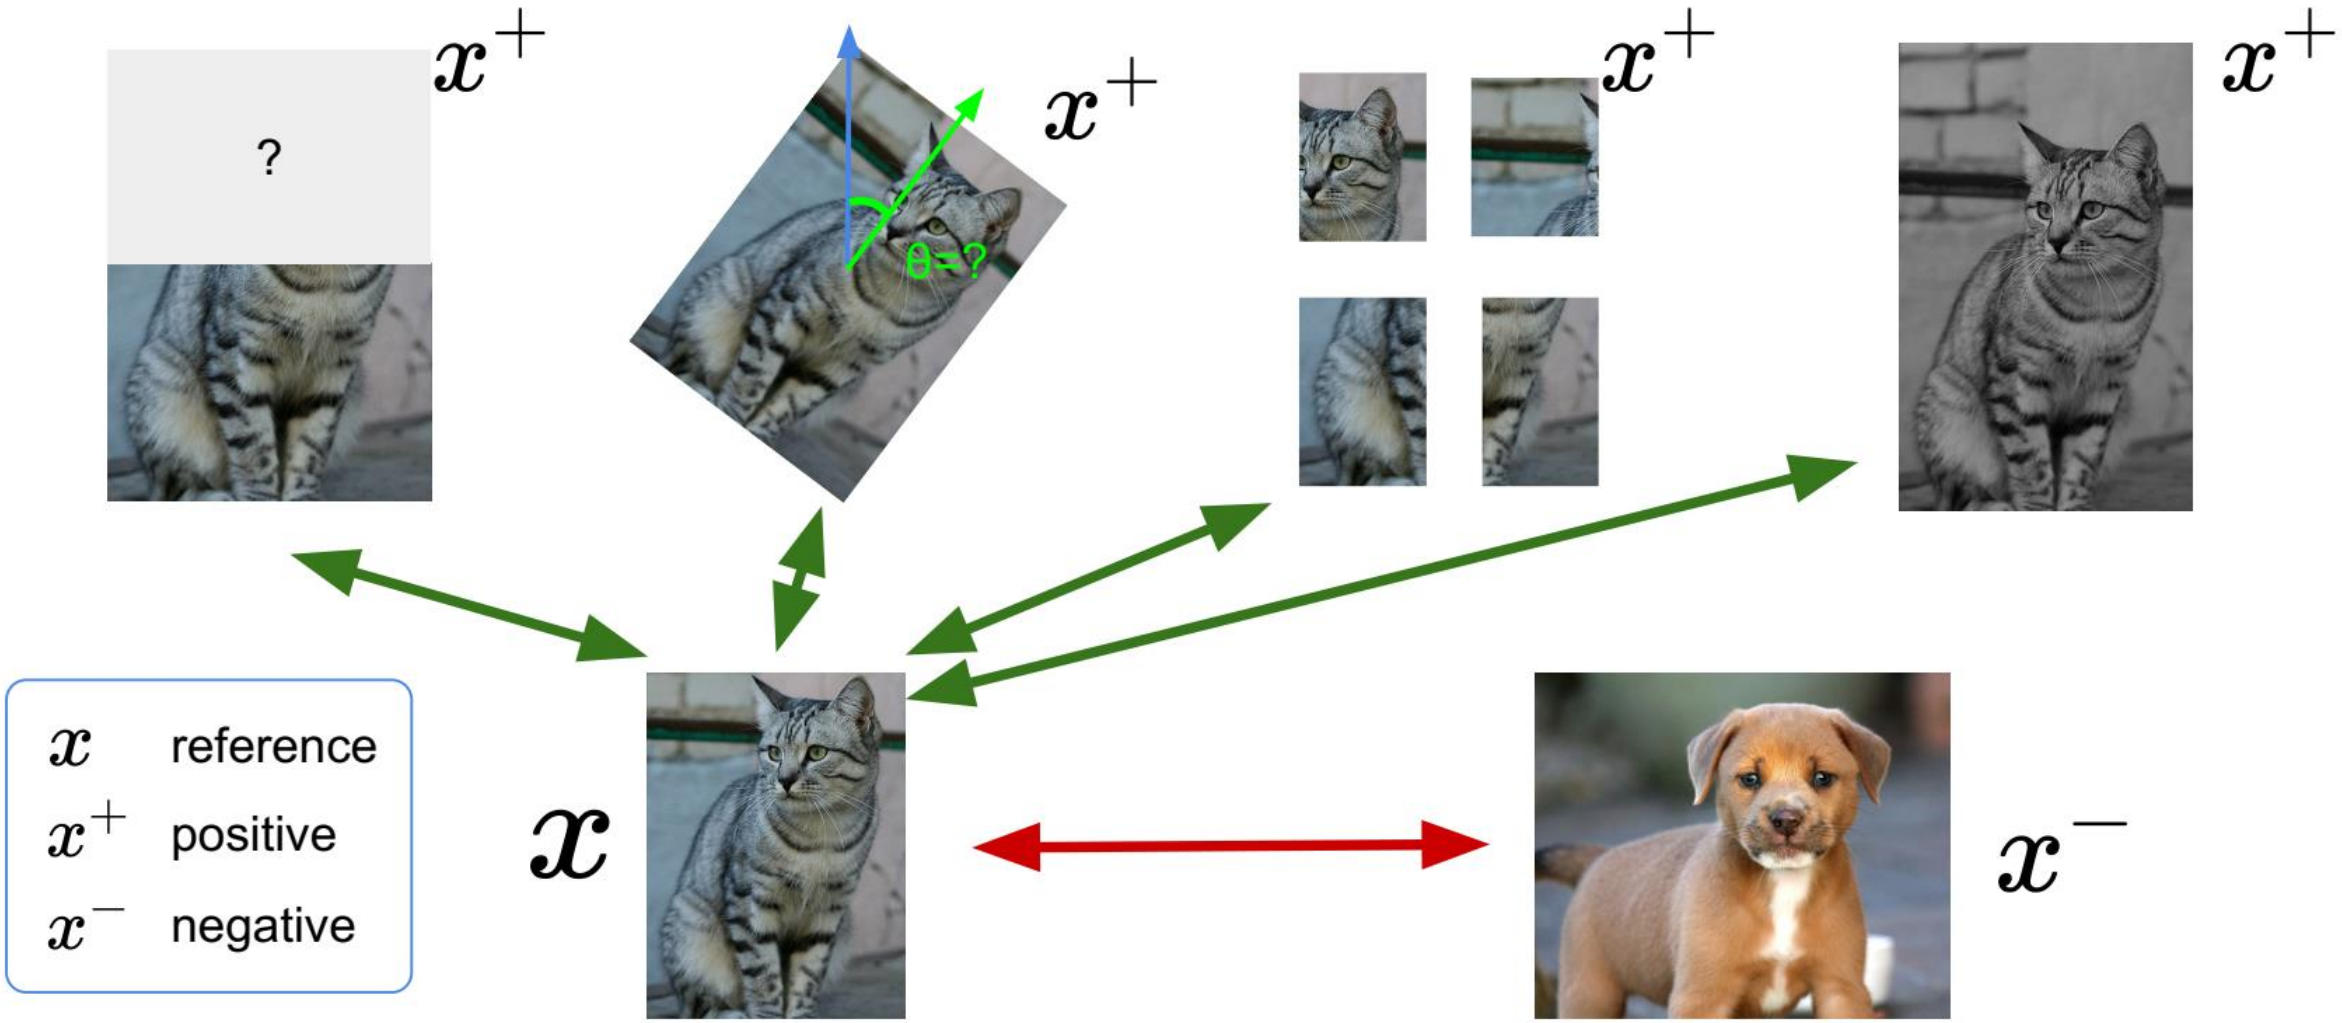

یک فرمولاسیون برای یادگیری مقابله‌ای

- می‌خواهیم با استفاده از آموزش یک کدگذار، ویژگی‌های مربوط به تصویر مرجع و مثبت به هم نزدیک باشند اما ویژگی‌های تصویر مرجع و تصویر منفی دور باشند

$$\text{score}(f(x), f(x^+)) >> \text{score}(f(x), f(x^-))$$

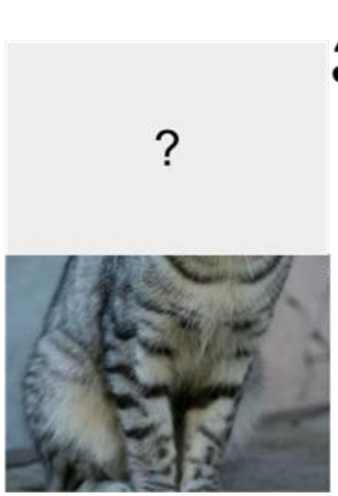

x^+

x reference
x^+ positive
x^- negative

x

x^-

یک فرمولاسیون برای یادگیری مقابله‌ای

- تابع ضرر برای حالتی که یک نمونه مثبت و N-1 نمونه منفی داشته باشیم:

$$L = -\mathbb{E}_X \left[\log \frac{\exp(s(f(x), f(x^+))}{\exp(s(f(x), f(x^+)) + \sum_{j=1}^{N-1} \exp(s(f(x), f(x_j^-))} \right]$$

x

x^+

x

x_1^-

x_2^-

x_3^-

...

یک فرمولاسیون برای یادگیری مقابله‌ای

- تابع ضرر برای حالتی که یک نمونه مثبت و N-1 نمونه منفی داشته باشیم:
  - شبیه به Softmax و Crossentropy است
  - به نام ضرر InfoNCE شناخته می‌شود

$$L = -\mathbb{E}_X \left[\log \frac{\exp(s(f(x), f(x^+))}{\exp(s(f(x), f(x^+)) + \sum_{j=1}^{N-1} \exp(s(f(x), f(x_j^-))} \right]$$

SimCLR

$$s(u,v) = \frac{u^T v}{||u||||v||}$$

- از فاصله کسینوسی به عنوان تابع امتیاز استفاده می‌کند
- نمونه‌های مثبت با استفاده از داده‌افزایی تولید می‌شوند

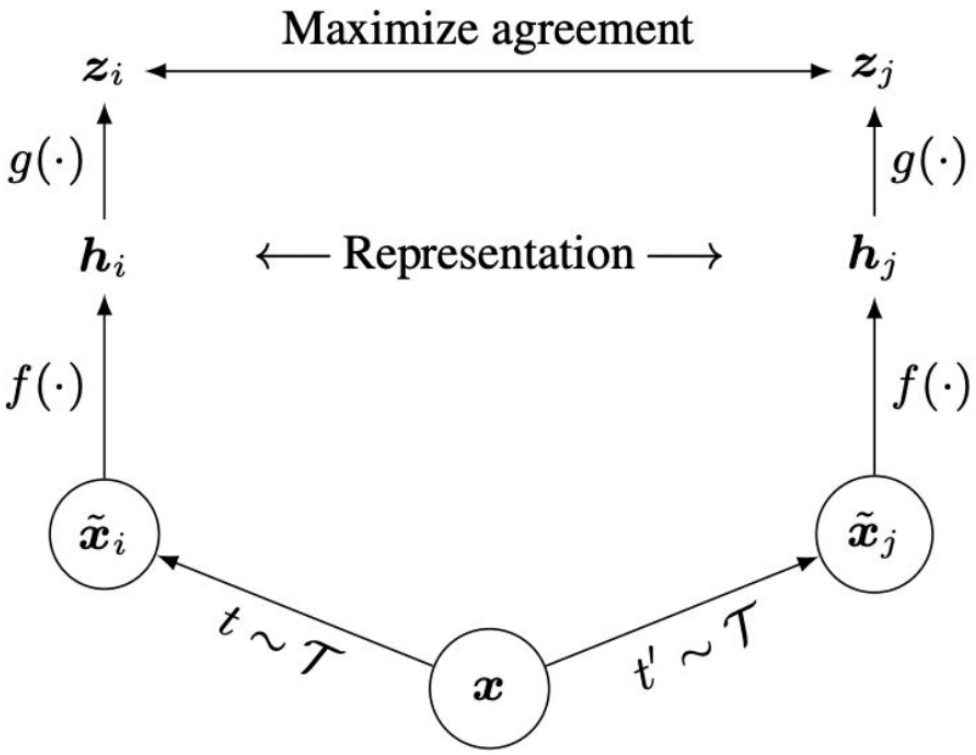

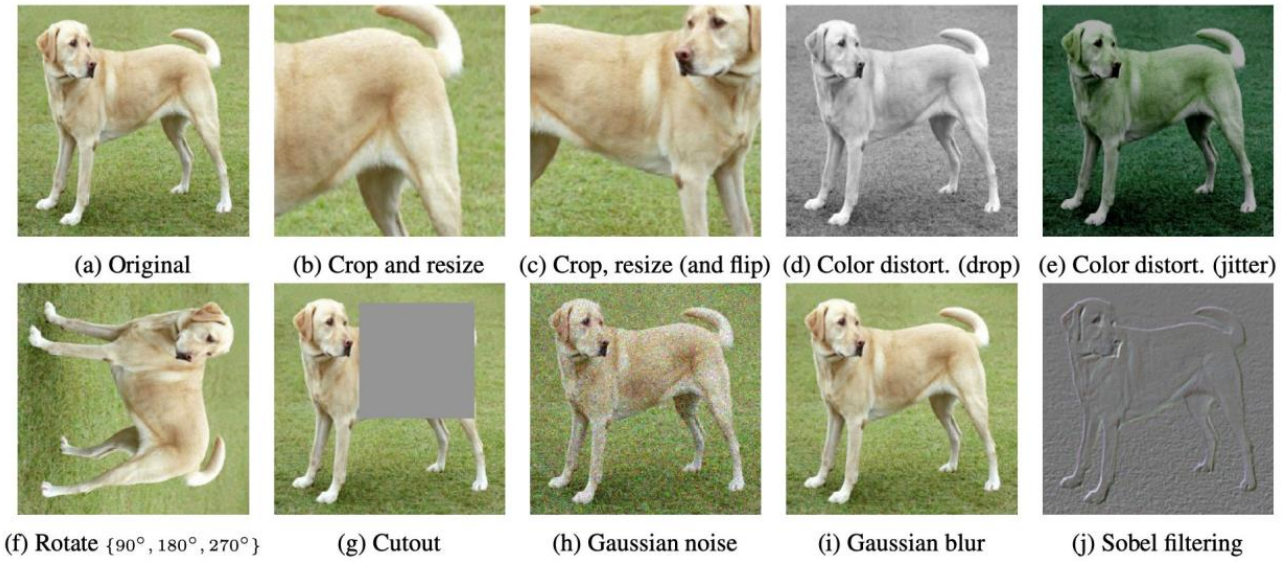

- از شبکه g (Projection Network) برای نگاشت ویژگی‌ها به فضایی که مقایسه انجام شود استفاده می‌کند

Chen, Ting, et al. "A simple framework for contrastive learning of visual representations." *International conference on machine learning*. PMLR, 2020.

SimCLR

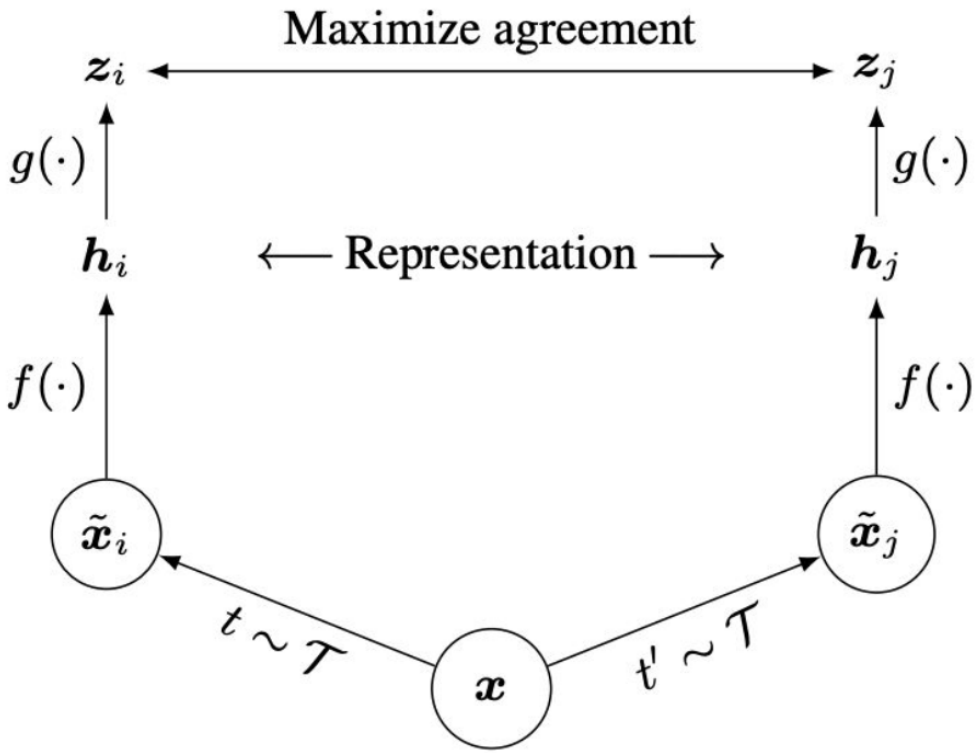

Algorithm 1 SimCLR's main learning algorithm.

input: batch size N, constant τ, structure of f, g, $\mathcal{T}$.
for sampled minibatch $\{\boldsymbol{x}_k\}_{k=1}^{N}$ **do**
  for all $k \in \{1, \ldots, N\}$ **do**
    draw two augmentation functions $t \sim \mathcal{T}$, $t' \sim \mathcal{T}$
    # the first augmentation
    $\tilde{\boldsymbol{x}}_{2k-1} = t(\boldsymbol{x}_k)$
    $\boldsymbol{h}_{2k-1} = f(\tilde{\boldsymbol{x}}_{2k-1})$ # representation
    $\boldsymbol{z}_{2k-1} = g(\boldsymbol{h}_{2k-1})$ # projection
    # the second augmentation
    $\tilde{\boldsymbol{x}}_{2k} = t'(\boldsymbol{x}_k)$
    $\boldsymbol{h}_{2k} = f(\tilde{\boldsymbol{x}}_{2k})$ # representation
    $\boldsymbol{z}_{2k} = g(\boldsymbol{h}_{2k})$ # projection
  end for
  for all $i \in \{1, \ldots, 2N\}$ and $j \in \{1, \ldots, 2N\}$ **do**
    $s_{i,j} = \boldsymbol{z}_i^\top \boldsymbol{z}_j / (\|\boldsymbol{z}_i\| \|\boldsymbol{z}_j\|)$ # pairwise similarity
  end for
  define $\ell(i, j)$ **as** $\ell(i, j) = -\log \frac{\exp(s_{i,j}/\tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i]} \exp(s_{i,k}/\tau)}$
  $\mathcal{L} = \frac{1}{2N} \sum_{k=1}^{N} [\ell(2k-1, 2k) + \ell(2k, 2k-1)]$
  update networks f and g to minimize $\mathcal{L}$
end for
return encoder network $f(\cdot)$, and throw away $g(\cdot)$

Chen, Ting, et al. "A simple framework for contrastive learning of visual representations." *International conference on machine learning*. PMLR, 2020.

SimCLR

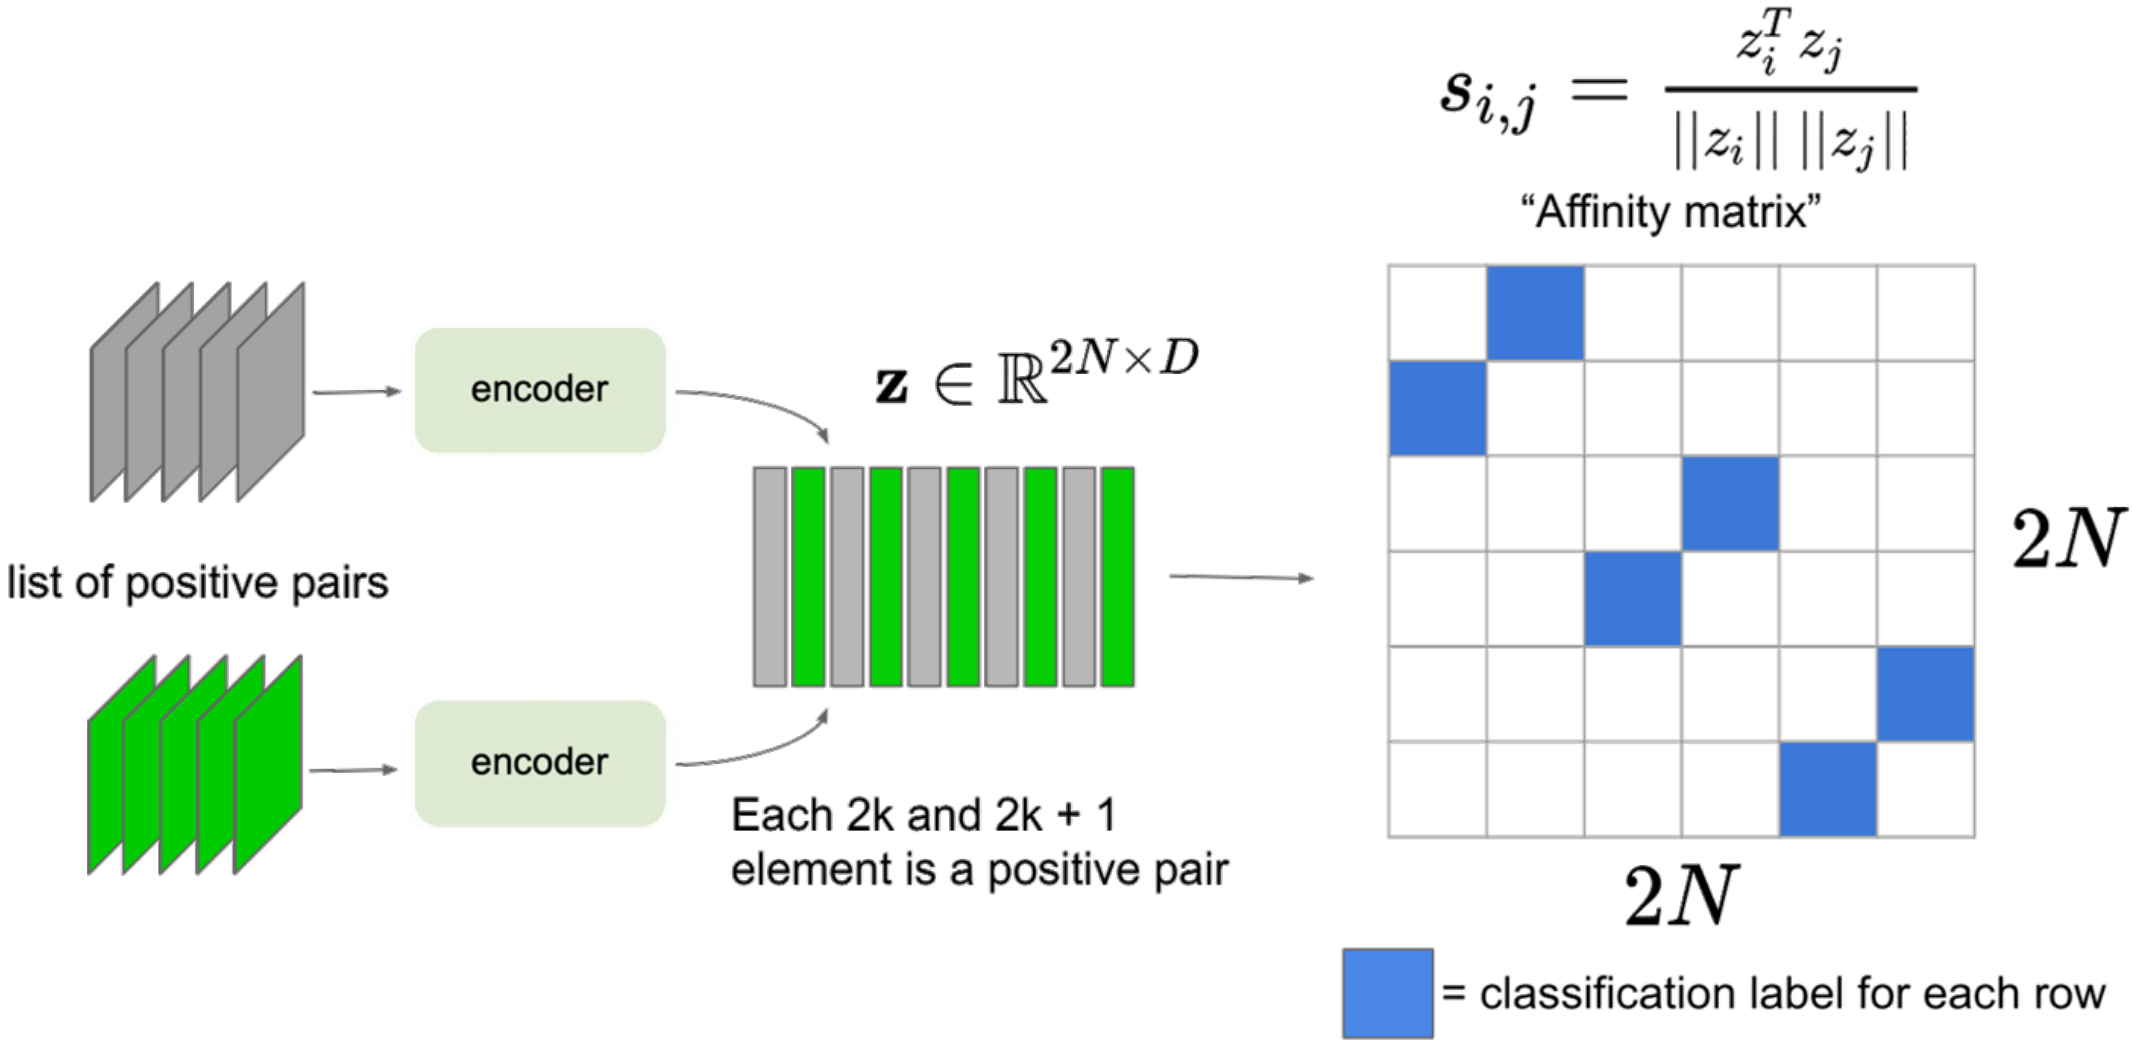

Chen, Ting, et al. "A simple framework for contrastive learning of visual representations." *International conference on machine learning*. PMLR, 2020.

SimCLR: یادگیری نیمه‌نظارتی

- یادگیری بازنمایی توسط تمام تصاویر ImageNet انجام شده است
- سپس، با درصد کمی از نمونه‌های دارای برچسب تنظیم دقیق شده است

Method	Architecture	Label fraction (Top 5) 1%	10%
Supervised baseline	ResNet-50	48.4	80.4
Methods using other label-propagation:			
Pseudo-label	ResNet-50	51.6	82.4
VAT+Entropy Min.	ResNet-50	47.0	83.4
UDA (w. RandAug)	ResNet-50	-	88.5
FixMatch (w. RandAug)	ResNet-50	-	89.1
S4L (Rot+VAT+En. M.)	ResNet-50 (4×)	-	91.2
Methods using representation learning only:			
InstDisc	ResNet-50	39.2	77.4
BigBiGAN	RevNet-50 (4×)	55.2	78.8
PIRL	ResNet-50	57.2	83.8
CPC v2	ResNet-161(∗)	77.9	91.2
SimCLR (ours)	ResNet-50	75.5	87.8
SimCLR (ours)	ResNet-50 (2×)	83.0	91.2
SimCLR (ours)	ResNet-50 (4×)	**85.8**	**92.6**

Table 7. ImageNet accuracy of models trained with few labels.

Chen, Ting, et al. "A simple framework for contrastive learning of visual representations." *International conference on machine learning*. PMLR, 2020.

Projection Head :SimCLR

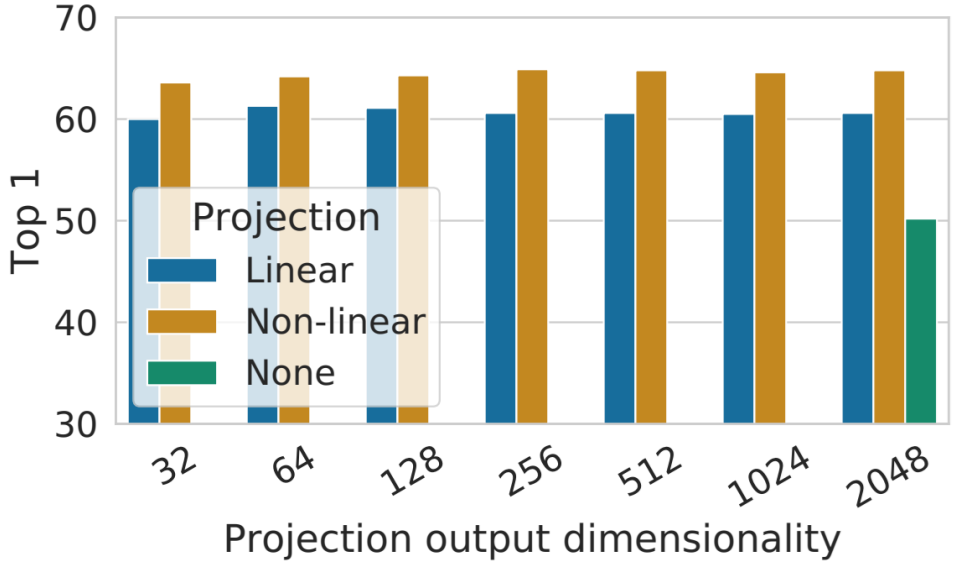

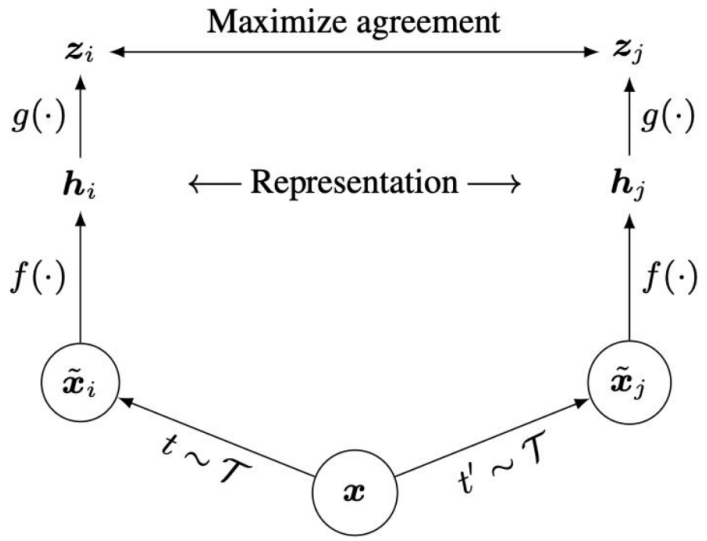

- نگاشت خطی و غیرخطی باعث بهبود یادگیری بازنمایی شده‌اند
- توضیح احتمالی:
  - هدف یادگیری مقابله‌ای ممکن است اطلاعات مفید را برای کارهای پایین‌دستی (downstream) حذف کند
  - فضای بازنمایی z به گونه‌ای آموزش داده شده است که نسبت به تبدیل داده‌ها نامتغیر باشد
  - با حذف g، اطلاعات بیشتری را می‌توان در فضای نمایش h حفظ کرد

Chen, Ting, et al. "A simple framework for contrastive learning of visual representations." *International conference on machine learning*. PMLR, 2020.

Batch Size :SimCLR

- اندازه دسته و همچنین تعداد دوره اثر زیادی در عملکرد بازنمایی‌های آموخته شده دارند
- اندازه دسته بزرگ نیاز به حافظه بسیار زیاد در زمان آموزش ایجاد می‌کند

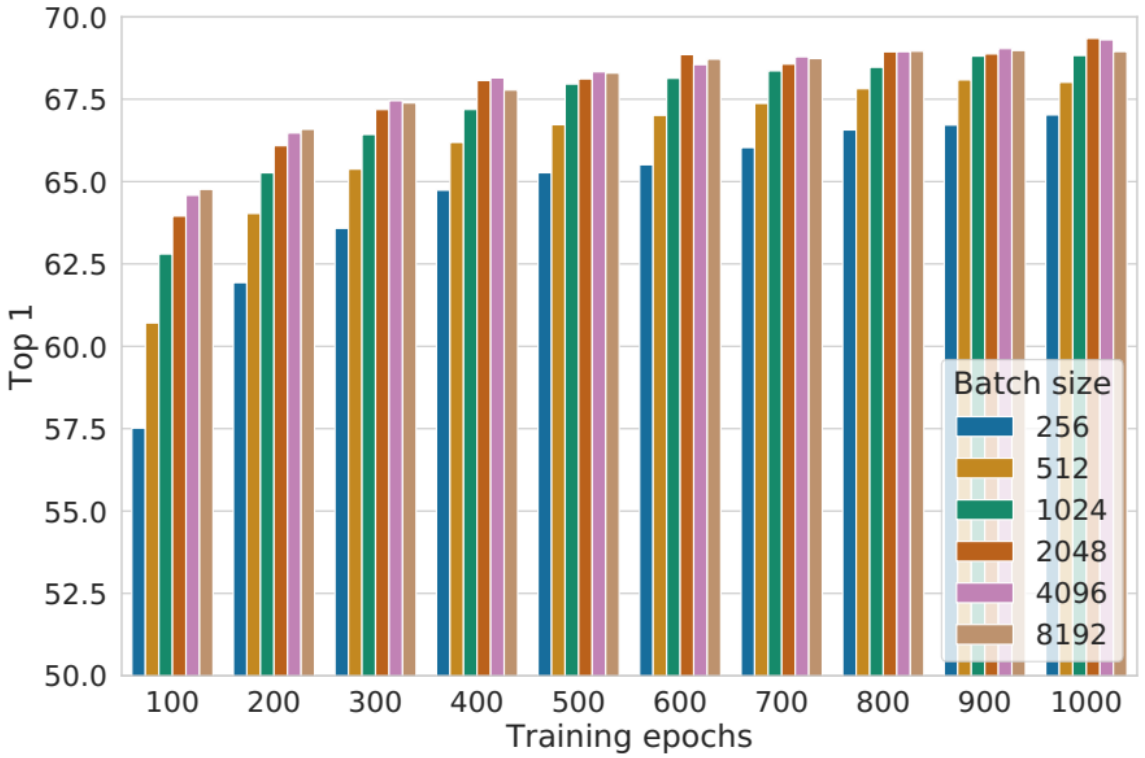

Figure 9. Linear evaluation models (ResNet-50) trained with different batch size and epochs. Each bar is a single run from scratch.[10]

Chen, Ting, et al. "A simple framework for contrastive learning of visual representations." *International conference on machine learning*. PMLR, 2020.

یادگیری مقابله‌ای تکانه‌ای (MOCO)

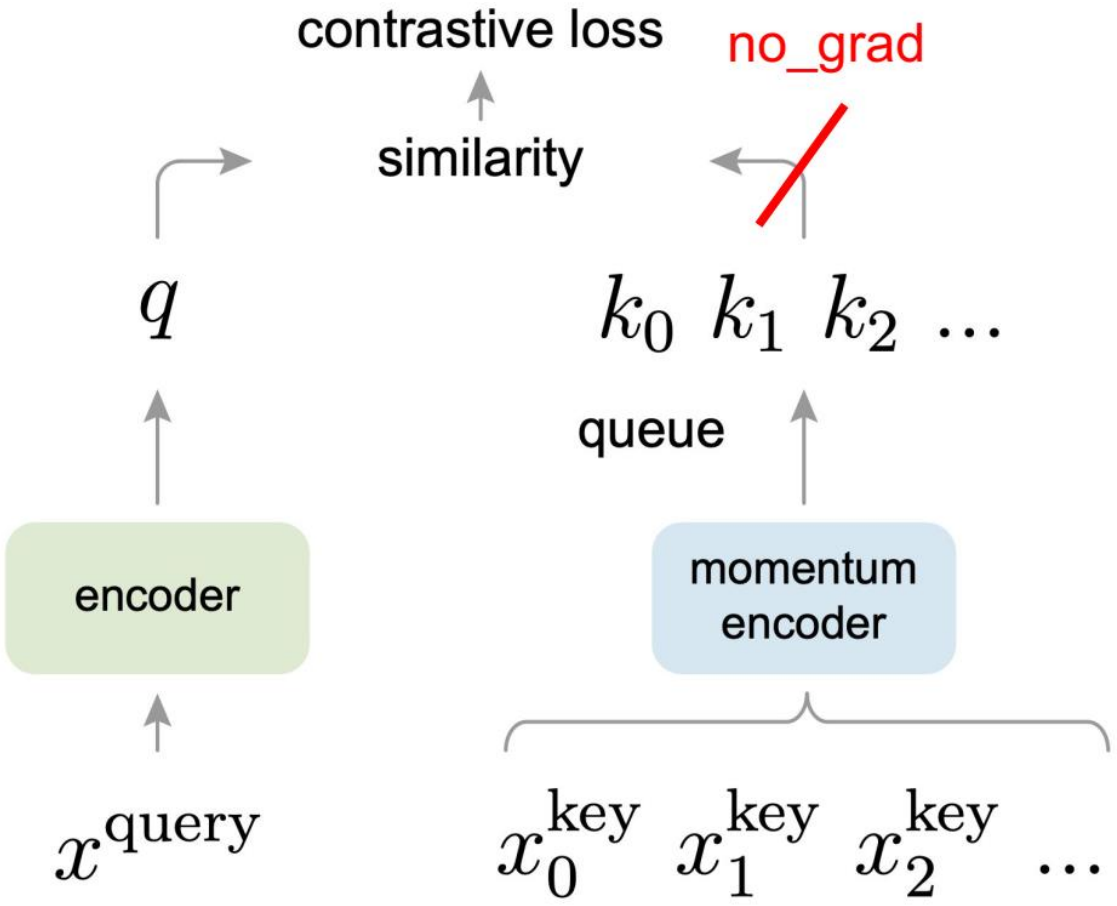

- تفاوت‌های کلیدی با SimCLR:
  - یک صف پویا از کلیدها (نمونه های منفی) نگهداری می‌شود
  - محاسبه گرادیان‌ها و به‌روزرسانی تنها برای کدگذار query انجام می‌شود
  - اندازه mini-batch از تعداد کلیدها جدا می‌شود؛ می‌تواند تعداد زیادی نمونه منفی را پشتیبانی کند
  - کدگذار مربوط به کلیدها به صورت آهسته و با استفاده از قاعده به‌روزرسانی تکانه‌ای به‌روز می‌شود:

$$\theta_{\text{k}} \leftarrow m\theta_{\text{k}} + (1-m)\theta_{\text{q}}$$

He, Kaiming, et al. "Momentum contrast for unsupervised visual representation learning." *CVPR*, 2020.

Algorithm 1 Pseudocode of MoCo in a PyTorch-like style.

```
# f_q, f_k: encoder networks for query and key
# queue: dictionary as a queue of K keys (CxK)
# m: momentum
# t: temperature

f_k.params = f_q.params # initialize
for x in loader: # load a minibatch x with N samples
  x_q = aug(x) # a randomly augmented version
  x_k = aug(x) # another randomly augmented version

  q = f_q.forward(x_q) # queries: NxC
  k = f_k.forward(x_k) # keys: NxC
  k = k.detach() # no gradient to keys

  # positive logits: Nx1
  l_pos = bmm(q.view(N,1,C), k.view(N,C,1))

  # negative logits: NxK
  l_neg = mm(q.view(N,C), queue.view(C,K))

  # logits: Nx(1+K)
  logits = cat([l_pos, l_neg], dim=1)

  # contrastive loss, Eqn.(1)
  labels = zeros(N) # positives are the 0-th
  loss = CrossEntropyLoss(logits/t, labels)

  # SGD update: query network
  loss.backward()
  update(f_q.params)

  # momentum update: key network
  f_k.params = m*f_k.params+(1-m)*f_q.params

  # update dictionary
  enqueue(queue, k) # enqueue the current minibatch
  dequeue(queue) # dequeue the earliest minibatch
```

bmm: batch matrix multiplication; mm: matrix multiplication; cat: concatenation.

Generate N positive pairs by sampling data augmentation functions

Encode samples

Use the running queue of keys as the negative samples

InfoNCE loss

Update f_k through momentum

Update the FIFO negative sample queue

MOCO V2

- یک ایده ترکیبی از SimCLR و MOCO:
  - از SimCLR: نگاشت غیرخطی و داده‌افزایی قوی
  - از MOCO: به‌روزرسانی مبتنی بر تکانه که اجازه آموزش با تعداد نمونه منفی زیاد بر روی حافظه محدود را می‌دهد

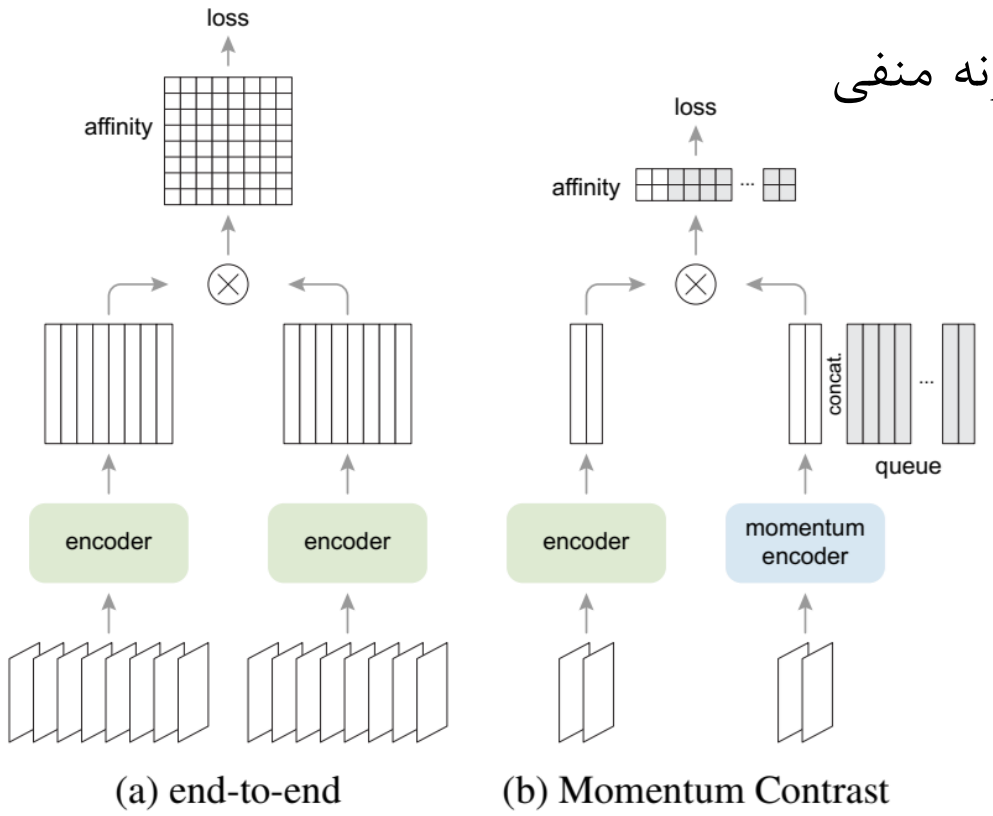

(a) end-to-end (b) Momentum Contrast

case	unsup. pre-train MLP	aug+	cos	epochs	ImageNet acc.	VOC detection AP_{50}	AP	AP_{75}
supervised					76.5	81.3	53.5	58.8
MoCo v1				200	60.6	81.5	55.9	62.6
(a)	✓			200	66.2	82.0	56.4	62.6
(b)		✓		200	63.4	82.2	56.8	63.2
(c)	✓	✓		200	67.3	**82.5**	57.2	63.9
(d)	✓	✓	✓	200	67.5	82.4	57.0	63.6
(e)	✓	✓	✓	**800**	**71.1**	**82.5**	**57.4**	**64.0**

Table 1. **Ablation of MoCo baselines**, evaluated by ResNet-50 for (i) ImageNet linear classification, and (ii) fine-tuning VOC object detection (mean of 5 trials). "**MLP**": with an MLP head; "**aug+**": with extra blur augmentation; "**cos**": cosine learning rate schedule.

Chen, Xinlei, et al. "Improved baselines with momentum contrastive learning." *arXiv,* 2020.

MOCO V2

- یک ایده ترکیبی از SimCLR و MOCO:
  - از SimCLR: نگاشت غیرخطی و داده‌افزایی قوی
  - از MOCO: به‌روزرسانی مبتنی بر تکانه که اجازه آموزش با تعداد نمونه منفی زیاد بر روی حافظه محدود را می‌دهد

case	unsup. pre-train MLP	aug+	cos	epochs	batch	ImageNet acc.
MoCo v1 [6]				200	256	60.6
SimCLR [2]	✓	✓	✓	200	256	61.9
SimCLR [2]	✓	✓	✓	200	8192	66.6
MoCo v2	✓	✓	✓	200	256	**67.5**
*results of **longer** unsupervised training follow:*						
SimCLR [2]	✓	✓	✓	1000	4096	69.3
MoCo v2	✓	✓	✓	800	256	**71.1**

Table 2. **MoCo *vs.* SimCLR**: ImageNet linear classifier accuracy (**ResNet-50, 1-crop 224×224**), trained on features from unsupervised pre-training. "aug+" in SimCLR includes blur and stronger color distortion. SimCLR ablations are from Fig. 9 in [2] (we thank the authors for providing the numerical results).

case	unsup. pre-train MLP	aug+	cos	epochs	ImageNet acc.	VOC detection AP_{50}	AP	AP_{75}
supervised					76.5	81.3	53.5	58.8
MoCo v1				200	60.6	81.5	55.9	62.6
(a)	✓			200	66.2	82.0	56.4	62.6
(b)		✓		200	63.4	82.2	56.8	63.2
(c)	✓	✓		200	67.3	**82.5**	57.2	63.9
(d)	✓	✓	✓	200	67.5	82.4	57.0	63.6
(e)	✓	✓	✓	**800**	**71.1**	**82.5**	**57.4**	**64.0**

Table 1. **Ablation of MoCo baselines**, evaluated by ResNet-50 for (i) ImageNet linear classification, and (ii) fine-tuning VOC object detection (mean of 5 trials). "**MLP**": with an MLP head; "**aug+**": with extra blur augmentation; "**cos**": cosine learning rate schedule.

Chen, Xinlei, et al. "Improved baselines with momentum contrastive learning." *arXiv,* 2020.

جانمایی کلمات (Word Embedding)

- جانمایی کلمات اطلاعات بیشتر را در ابعاد بسیار کمتری قرار می‌دهد
- این بردارها را می‌توان با استفاده از حجم زیادی از متن پیش‌آموزش داد و در مجموعه داده‌های کوچک از آنها استفاده کرد

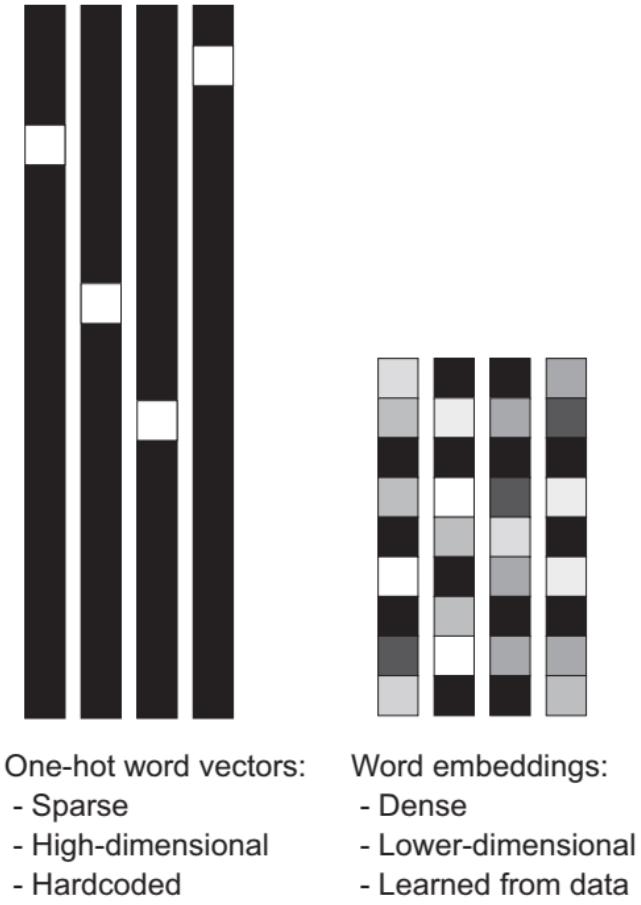

One-hot word vectors:
- Sparse
- High-dimensional
- Hardcoded

Word embeddings:
- Dense
- Lower-dimensional
- Learned from data

مدل زبان طبیعی

- در این مدل می‌خواهیم کلمه بعدی را پیش‌بینی کنیم
- هدف ما دستیابی به بردارهای جانمایی است و وزن‌های دیگر شبکه هدف نیستند

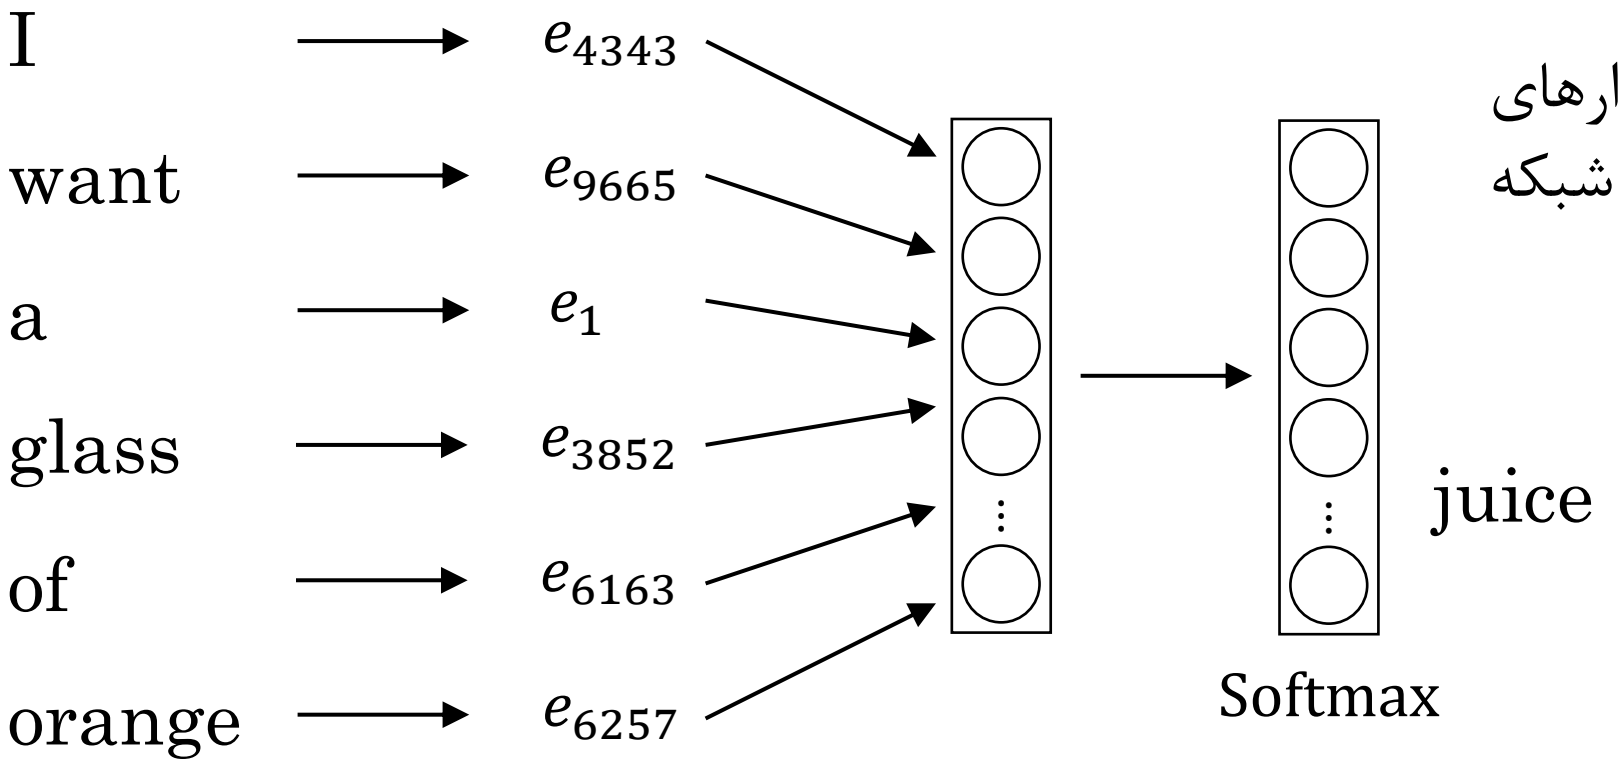

Bengio, Yoshua, et al. "A neural probabilistic language model." *The journal of machine learning research*, 2003.